

ODR, компиляция и линковка

Гусев Илья

Московский физико-технический институт

Москва, 2017

Содержание

- 1 Исходный код
 - Объявления и определения
 - ODR
- 2 После исходного кода
 - Общая схема
 - Компиляция
 - Линковка
 - Загрузка исполняемого файла
- 3 Библиотеки
 - Статические библиотеки
 - Shared библиотеки
 - Shared библиотеки
 - Динамически загружаемые библиотеки
- 4 C++ - mangling
 - Перегрузка функций
 - Конструкторы статических объектов

Declaration vs definition

Declaration

- 1 A declaration may introduce one or more names into a translation unit or redeclare names introduced by previous declarations. If so, the declaration specifies the interpretation and attributes of these names.
- 2 Проще говоря, объявление(declaration) - всего лишь имя. Влиять она может лишь на компиляцию, шаблоны и, например, аргументы функций.
- 3 Примеры объявлений:

```
extern int a; // declares a
extern const int c; // declares c
int f(int); // declares f
struct S; // declares S
typedef int Int; // declares Int
extern X anotherX; // declares anotherX
using N::d; // declares d
```

Declaration vs definition

Declaration

A declaration is a definition unless:

- ❶ contains the extern specifier or a linkage-specification
- ❷ doesn't contain an initializer,
- ❸ doesn't contain function body,
- ❹ a function without specifying the function's body,
- ❺ a static data member in a class definition,
- ❻ a class name declaration,
- ❼ an opaque-enum-declaration,
- ❽ a template-parameter,
- ❾ a parameter-declaration in a function declarator that is not the declarator of a function-definition
- ❿ a typedef declaration,
- ⓫ an alias-declaration,
- ⓬ a using-declaration,
- ⓭ a static_assert-declaration,
- ⓮ an attribute declaration,
- ⓯ an empty-declaration,
- ⓰ a using-directive.

Declaration vs definition

Declaration

Примеры определений:

```
int a; // defines a
extern const int c = 1; // defines c
int f(int x) { return x+a; } // defines f and defines x
struct S { int a; int b; }; // defines S, S::a, and S::b
struct X { // defines X
    int x; // defines non-static data member x
    static int y; // declares static data member y
    X(): x(0) { } // defines a constructor of X
};
int X::y = 1; // defines X::y
enum { up, down }; // defines up and down
namespace N { int d; } // defines N and N::d
namespace N1 = N; // defines N1
X anX; // defines anX
```

Declaration vs definition

Больше примеров

```
// This is the definition of a uninitialized global variable
int x_global_uninit;
// This is the definition of a initialized global variable
int x_global_init = 1;
// This is the definition of a uninitialized global variable,
// albeit one that can only be accessed by name in this C file
static int y_global_uninit;
// This is the definition of a initialized global variable,
// albeit one that can only be accessed by name in this C file
static int y_global_init = 2;
// This is a declaration of a global variable that exists somewhere
// else in the program
extern int z_global;
// This is a declaration of a function that exists somewhere else
// in the program (you can add "extern" beforehand if you like,
// but it's not needed)
int fn_a(int x, int y);
```

Declaration vs definition

Больше примеров

```
// This is a definition of a function, but because it is marked as  
// static, it can only be referred to by name in this C file alone  
static int fn_b(int x)  
{  
    return x+1;  
}  
  
// This is a definition of a function.  
// The function parameter counts as a local variable  
int fn_c(int x_local)  
{  
    // This is the definition of an uninitialized local variable  
    int y_local_uninit;  
    // This is the definition of an initialized local variable  
    int y_local_init = 3;  
    // Code that refers to local and global variables and other  
    // functions by name  
    x_global_uninit = fn_a(x_local, x_global_init);  
    y_local_uninit = fn_a(x_local, y_local_init);  
    y_local_uninit += fn_b(z_global);  
    return (y_global_uninit + y_local_uninit);  
}
```

One definition rule

- 1 A source file together with all the headers and source files included via the preprocessing directive `include`, less any source lines skipped by any of the conditional inclusion preprocessing directives, is called a **translation unit**.
- 2 **No translation unit shall contain more than one definition of any variable, function, class type, enumeration type, or template.**
- 3 Every program shall contain **exactly one definition** of every non-inline function or variable that is odr-used in that program; no diagnostic required. The definition can appear explicitly in the program, it can be found in the standard or a user-defined library, or (when appropriate) it is implicitly defined. An inline function shall be defined in every translation unit in which it is odr-used.
- 4 Переменная считается odr-used, если она находится в потенциально вычисляемом выражении.

One definition rule - complete class types

Exactly one definition of a class is required in a translation unit if the class is used in a way that requires the class type to be complete.

The following complete translation unit is well-formed, even though it never defines X:

```
struct X; // declare X as a struct type  
struct X* x1; // use X in pointer formation  
X* x2; // use X in pointer formation
```

One definition rule - исключения

There can be more than one definition of:

- 1 a class type
- 2 enumeration type
- 3 inline function with external linkage
- 4 class template
- 5 non-static function template static data member of a class template
- 6 member function of a class template
- 7 template specialization for which some template parameters are not specified

in a program provided that each definition appears in a different translation unit, and provided the definitions satisfy the following requirements:

One definition rule - исключения

- 1 каждое определение должно состоять из одной и той же последовательности токенов;
- 2 имена, использованные в определении (в т.ч. использованные неявно), должны относиться к одним и тем же сущностям, или быть определены в самом определении;
- 3 в каждом определении сущности должны иметь одно и то же связывание;
- 4 если в определении есть вызов функции со значением аргумента по умолчанию, считается что токены значения вставляются в определение, и таким образом подпадают под правила, написанные выше;
- 5 если определение - это класс с неявно-определенным конструктором, он должен вызывать одни и те же конструкторы своих членов и базовых классов.

One definition rule - примеры

<i>// Единица трансляции 1:</i>		<i>// Единица трансляции 2:</i>
<code>int x = 1;</code>		<code>int x = 1;</code>
<code>int y = 1;</code>		<code>int y = 1;</code>
<code>decltype(x) xx;</code>		
<i>// OK, "x" использована в не-вычисляемом контексте.</i>		
<i>// нарушение ODR, "y" определена в двух единицах</i>		
<i>// трансляции и ODR-использована.</i>		
<code>int z = y;</code>		

One definition rule - примеры

<i>// Единица трансляции 1:</i>		<i>// Единица трансляции 2:</i>
<code>int x = 1;</code>		<code>int x = 1;</code>
<code>int y = 1;</code>		<code>int y = 1;</code>
<code>decltype(x) xx;</code>		
<i>// OK, "x" использована в не-вычисляемом контексте.</i>		
<i>// нарушение ODR, "y" определена в двух единицах</i>		
<i>// трансляции и ODR-использована.</i>		
<code>int z = y;</code>		

One definition rule - примеры

Разные конструкторы базовых классов при вызове неявно определенного конструктора `D::D()`.

// Единица трансляции 1:

```
struct X {  
    X(int);  
    X(int, int);  
};
```

```
X::X(int = 0) { }
```

```
class D: public X { };
```

|
|
|
|
|
|
|
|
|
|
|
|

// Единица трансляции 2:

```
struct X {  
    X(int);  
    X(int, int);  
};
```

```
X::X(int = 0, int = 0) { }
```

```
class D: public X { };
```

One definition rule - примеры

"Имена, использованные в определении должны относиться к одним и тем же сущностям"

```
// g.h
void f(float t);
inline void g() { f(1); }
```

```
// f_int.h
void f(int);
```

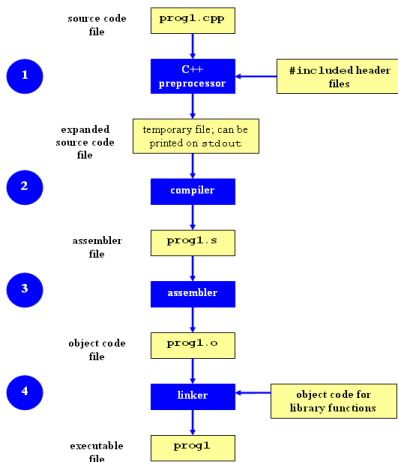
```
// main.cpp
#include "g.h"
int main() {
    g();
}
```

```
// f.cpp
#include "g.h"
#include "f_int.h"
void f(int) {}
void f(float t) {}
```

Общая схема

g++ prog1.cpp

- 1 Препроцессор копирует содержимое включённых файлов в исходный код, разворачивает макросы и подставляет константы, переопределённые с помощью `#define`.
- 2 Развёрнутый исходный код компилируется в платформозависимый ассемблер (.s). Включение вывода: `-S`
- 3 Ассемблерный код собирается в объектный код платформы (.o). Смотреть: `nm, objdump`.
- 4 Объектный код связывается с другими объектными файлами и библиотеками.




Компиляция

- 1 Токенизация
- 2 Построение промежуточного дерева по грамматике
- 3 Построение abstract-syntax tree (AST)
- 4 Построение платформо-зависимого дерева
- 5 Создание ассемблерного кода.


Линковка

На выходе с компилятора приходят объектные файлы. Они ничего не знают о существовании друг друга и их надо объединить в один, заполнив их "пропуски". Пример одиночного объектного файла:




Линковка - собранный файл

Пример собранного исполняемого файла:



Загрузка исполняемого файла

- 1 Глобальные переменные кладутся в память процесса as is.
- 2 Локальные переменные кладутся на стек, который растёт при вызовах функций и уменьшается при их завершении.
- 3 Динамические переменные расходуют память кучи, системные malloc и free управляют этой частью процесса.
- 4 bss - фрагмент неинициализированных переменных, заполнен нулями
- 5 Кроме того, затронут mapping файлов в память и пространство ядра (kernel space).



Статические библиотеки

- 1 Самая простая версия библиотек
- 2 Linux: `lib*.a`, Windows: `*.lib`
- 3 Библиотека может состоять из нескольких `.o` файлов.
- 4 Библиотека участвует в линковке объектными файлами, то есть тянется не вся библиотека, а только объектники, которые заполняют какой-либо 'пропуск'. При этом, тянется всё, что есть в этом объектном файле, в том числе новые 'пропуски'.
- 5 Линковка библиотек только после линковки частей программы, и только если есть 'пропуски'.
- 6 Библиотеки линкуются строго по порядку. Если вдруг библиотека-2 (идущая после библиотеки-1) требует что-то, что есть в незагруженном объектнике библиотеки-1, линкер это что-то не найдёт!

Проблемы статических библиотек

- 1 Каждый исполняемый файл содержит копию библиотеки → исполняемые файлы занимают кучу места.
- 2 Если мы хотим поменять код библиотеки нужно перелинковывать ВСЕ исполняемые файлы.

Shared библиотеки

- 1 *.so, *.dll, *.dylib.
- 2 Линкер просто оставляет некоторые 'пропуски' открытыми, записывая, что они должны заполняться из такой-то shared библиотеки.
- 3 Код библиотеки не включается в исполняемый файл.
- 4 Во время запуска программы (до исполнения main) операционная система направляет маленькую версию линкера (ld.so) на оставшиеся 'пропуски'.
- 5 Если мы захотим поменять код, скажем, printf - нам не нужно перелинковывать все исполняемые файлы.
- 6 Загрузка shared библиотек происходит целиком, а не по объектным файлам!
- 7 `ldd <имя исполняемого файла>` чтобы посмотреть, какие библиотеки он захватывает.

Windows DLL

- ❶ Нужно явно указывать символы для экспорта одним из 3 вариантов:
 - ❶ `__declspec(dllexport) int my_exported_function(int x, double y);`
 - ❷ `LINK.EXE /dll /export:my_exported_function`
 - ❸ `LINK.EXE /dll /DEF:def_file`
- ❷ Информация об экспортируемых символах и их местонахождении хранится в .lib файле (не статическая библиотека, другое!). Этот файл нужен исполняемому, чтобы корректно слинковать DLL.
- ❸ Можно ещё задавать импорты для лучшей оптимизации:
 - ❶ `__declspec(dllimport) int function_from_some_dll(int x, double y);`
 - ❷ `__declspec(dllimport) extern int global_var_from_some_dll;`

Windows DLL

Что может получиться после линковки:

- 1 library.DLL: код и данные библиотеки, непосредственно используется исполняемым файлом.
- 2 library.LIB: файл, в котором описываются экспортируемые DLL символы.
- 3 library.EXP: ещё один файл с описаниями символов, нужен для разрешения циклических зависимостей.
- 4 library.ILK: при опции линкера /INCREMENTAL, хранит состояние инкрементальной компоновки, для ускорения перекомпиляции.
- 5 library.PDB: при опции линкера /DEBUG, содержит отладочные данные и сведения о состоянии проекта, например информацию о типах.
- 6 library.MAP: при опции линкера /MAP, хранит расположение функций и данных в DLL.

Windows DLL

Что может быть до линковки:

- 1 library.LIB: файлы других библиотек, в которых описываются экспортируемые ими символы.
- 2 library.LIB: статические библиотеки - набор объектных файлов. Неоднозначное расширение :)
- 3 library.DEF: определение библиотеки, контроль некоторых настроек библиотеки, в частности - в нём можно задавать экспортируемые символы.
- 4 library.EXP: файл с описаниями символов линкуемых библиотек, нужен для разрешения циклических зависимостей.
- 5 library.ILK: см. выше.
- 6 library.RES: ресурсный файл с разными GUI штуками, локализациями и всем таким, это всё нужно исполняемому файлу

Динамически загружаемые библиотеки (настоящие DLL)

- 1 Загрузка библиотеки в любом месте программы, не только до `main`.
- 2 `dlopen` и `dlsym` (или `LoadLibrary` и `GetProcAddress`).
- 3 `dlopen` - берёт библиотеку и загружает её в память процесса.
- 4 `dlsym` - берёт имя символа и возвращает указатель на его местонахождение в в загруженной области памяти.

Перегрузка функций

- 1 В Си нельзя перегружать функции, в C++ можно.
- 2 Пример: `int max(int x, int y); float max(float x, float y);`
- 3 А что делать линкеру, он же по имени символы ищет?

Mangling

- ❶ Решение:
 - ❶ `int max(int x, int y) -> имя - _Z3maxii`
 - ❷ `float max(float x, float y) -> имя - _Z3maxff`
- ❷ Всё сложнее для классов.
- ❸ И ещё сложнее для шаблонов.
- ❹ `extern "C"` у объявления и определения - убирает mangling для совместимости кода на Си и C++.
- ❺ `extern "C"` игнорируется методами класса.

Конструкторы статических объектов

- 1 В Си инициализация статических объектов очень простая - просто копируем данные из data секции в память.
- 2 В C++ появились конструкторы.
- 3 Компилятор обязан составить список конструкторов, которые нужно вызвать перед запуском программы и включить в программу код, который все эти конструкторы вызовет.
- 4 В рамках одной единицы трансляции порядок конструирования закреплён.
- 5 Но в каком порядке конструкторы будут вызываться из разных единиц трансляции - неизвестно, будьте осторожны, особенно если они друг от друга зависят!

Полезные ссылки I



C++11 n3690

<http://www.open-std.org/jtc1/sc22/wg21/docs/papers/2013/n3690.pdf>



Статья про линковку

<https://www.lurklurk.org/linkers/linkers.html#file>



Habr: ODR

<https://habrahabr.ru/company/abbyy/blog/108166/>



SO: ODR

<https://ru.stackoverflow.com/questions/418755/Что-такое-Правило-одного-определения-one-definition-rule>



The C++ compilation process

<http://faculty.cs.niu.edu/~mcmahon/CS241/Notes/compile.html>



Хабр: Организация памяти

<https://habrahabr.ru/company/smartsoft/blog/185226/>